

C1/C2 机制重构：文献迁移与同账本筛查

2026-09-06 · Motion C12 / H67 / ep34 · TCAS-II 唯一电路出口

本轮结论：优先推进 C1 的有限父结果槽与精确重算；C2 转向原始权重延迟投递。共享部分和不再作为首选。新增方向保留 PSN 保守阈值判定，先验证统计机会。当前证据足以决定下一步开发顺序，尚不足以判断“稳录用”。

方向	实质变化	本轮证据	决定
C1	父结果可丢弃；缺失时直接重算当前行，研究取消后备父 SRAM	5,640 tile；四槽仅多 0.0188% 源项发射槽	第一优先，验证端口、时序与实际面积
C2	将最多两个原始权重向量延迟送入后续归约器空闲输入	2,880 模板；64 源窗口更新意图上界减少 19.49% / 23.73%	第二优先，先做低成本选择与捕获时序
新增	对 T=10 PSN 的单个输出建立剩余和区间，确定越阈结果后停算该输出	数学推导；尚无 ep34 收益统计	统计候选，暂不作为论文贡献

证据等级。表中所有新数字都是 CPU 操作计数或服务意图上界。没有新增 VCS、DC/PT、Formality 或布局布线结果；既有 C1/C2 的准入不能转移给新机制。没有整网 FPS 或系统加速比。

本轮实际完成了文献检索、三个研究分支的交叉审阅，以及五类可复现筛查：差分父图、有限锚点、固定森林重算、选择性部分和、原始权重暂存。结论经历了强对照修正，而非先定名字再找收益。

短文应从上述方向中选出一个在物理实现上胜出的机制。C1 与 C2 可以继续并行研究，但不预设把它们和新增方向堆进同一篇五页稿。

冻结边界仍为二值 ATLIF；105 个安装模块、93 个实际调用、81 个有消费者。12 个 sn2_q 未调用，与 12 个 attn_sn 结果无消费者是不同事实。本文的 INT8 是诊断权重或部署权重，绝不是把 ATLIF 改成实值载荷。

先验与可迁移的差异

可以借成熟原理，但必须证明迁移后改变了资源、执行或访存成本。下表给出最接近的来源，避免把相同代数重新命名为贡献。

先验	已有内容	本项目仍可检验的问题
Prosperity, HPCA 2025 [1]	二值脉冲的 product sparsity、子集父行与结果复用	固定小源集合能否用有界重算替代父结果后备存储？
Phi, ISCA 2025 [2]	模式加双向残差；零模式回退	在线小状态值得测，但正负修正与回退均不能当新代数
Transitive Array, ISCA 2025 [3]	GEMM 中间结果复用及配套调度、缓冲	不以“多一层复用”作贡献；比较实际状态、访问和控制成本
Checkmate / DTR [4,5]	存储与重新计算之间的交换	将重算收窄到 16 源二值支持及一次输出提交的硬件合同
Gamma, ASPLOS 2021 [6]	Gustavson、显式管理缓存、动态调度和重排	热槽、生命周期、重排本身不足以支撑新机制
RSR / RSR++, ICML 2025 [7]	二值/三值权重分组、共享归约和分发	动态激活模式不是充分区别；必须超过更便宜的单源暂存
ELSA, ISCA 2026 [8]	SNN 的 mini-batch Gustavson 与弹性执行	C2 保留已有预请求复用；新增价值应落在 Acc24 更新服务

纠正 idea 包中的一个前提。Prosperity 本来就在处理二值 spike；“ATLIF 变成二值后 product capture 不适用，改成加法森林即为新机制”不能成立。冻结 ep34 也不支持 Grok Bot 的实值 ATLIF 载荷假设。[1]

近期近邻仍是审稿风险。Comperity 的出版商摘要明确涉及邻行差分与无状态索引，在线日期为 2026-07-24。本轮未获得可核验全文，因此不能断言它没有覆盖某种小状态差分数据流。[9] 这也是本轮把 C1 主候选放到“原森林的可丢弃父存储”，而非仅给差分改名的原因之一。

文献检索已覆盖能改变当前候选排名的直接近邻。现在继续泛搜论文的边际作用低于验证捕获端口、重算取权重以及选择器开销；全文缺口保留在来源台账中。

C1：小状态换取有界重算

最有用的结果是：重排和重算必须配合；直接删存储会明显增加工作。同一子集森林、同一遍历顺序、同一 FIFO 替换、同一未消费者释放规则、同一槽数，逐对比较有后备存储与无后备存储。新模型没有额外响应载荷队列。

遍历	父结果槽	无后备时源项发射槽增加	被省去的后备读写意图	最差样本×算子增加
稳定次序	1	73.5303%	148,964	83.4756%
稳定次序	2	58.5834%	127,293	67.9365%
稳定次序	4	35.4006%	85,796	46.4430%
深度优先穿线	1	10.8801%	27,800	13.5010%
深度优先穿线	2	1.4161%	4,074	2.5636%
深度优先穿线	4	0.0188%	51	0.1589%

数据集：10 个已有样本 × 4 个瓶颈卷积 × K 分区 0/216/431 × 全部 47 个空间块，共 5,640 tile、360,000 条输入行；不是 5,184 万行全账本。非零输出行 168,756。基线源项发射槽为 276,614；两槽重算为 280,531，四槽为 276,666。

“源项发射槽”包含继承父结果所需的最小拷贝服务，并不等于纯加法数或真实时钟周期。后备读写意图也不是布局后能量。四槽方案只有 32 行缺父，增加 52 个源项发射槽；这不能推出 32 次物理 SRAM 缺失或芯片加速。


每槽 96 lane × 12 bit：两槽载荷 288 B，四槽 576 B，不含标签、工作寄存器、调度表及最终输出状态。既有九宏的物理容量为 18 KiB、当前任务有效父载荷为 9 KiB。容量差异不能直接换算成面积比例。

12 个比较轴共执行 194,406,912 次 lane 数值核对，零不一致。使用真实二值支持与固定种子的 INT8 诊断权重，包含整列 -128/+127；这验证整数重构，不证明冻结 FP32 网络等价或 AEE。

本轮负残差对照还显示：480 tile 上，负边可降低约 7.20%–11.23% 源项发射槽，但在额外每行一周期规划的敏感性模型中，孤立任务成本变差。它保留为对照，暂不抢占实现优先级。

C1：可审阅的数据流与验收点

工作名：有限父结果槽与精确重算。继承 Prosperity 子集代数 [1]、结果生命周期与重算思想 [4–6]；本项目要证明的电路增量，是在明确的源数界和提交协议下，是否能实际取消后备父宏而保持吞吐。



协议如下：冻结 64 行的原子任务及其 16 源支持；建立子集森林和深度优先穿线次序。调度当前行时查 2/4 个父槽。命中则读取父结果、发残差；缺失则以零为初值发当前行原始支持。父行不递归重放，当前输出只提交一次。未消费者后释放；有未来消费者的当前结果按同一 FIFO 规则入槽。

自然二值输入下，每 lane 的任意 16 源子集和在 $[-2048, 2032]$ ，可用 12 bit。最终卷积跨分区累加与输出协议保持原位宽合同。带符号桥、非法类型或身份不一致必须走足够位宽的原始计算回退；不能套用自然正源的 12 bit 证明。

公平实现矩阵。至少包括原九宏岛、同样穿线/槽数但有后备宏的版本、两槽与四槽无后备版本。相同权重交付、输出背压、时钟、工作寄存器和响应队列；穿线构建不得免费。另以零跳过、邻行差分、在线有限锚点作机制对照，不把其中最弱者作为唯一基线。

下一步必须解决的三个物理问题。第一，槽读取、未消费者释放及当前行写回能否在既定端口下推进。第二，重算增加的源项是否导致额外权重 SRAM 服务或打断原重用。第三，移除后备宏后，槽实现、选择器和穿线表是否吃掉面积与能量收益。

建议内部投入门：先在独立时序模型完成全源分区回放及背压；再以相同 3 ns 目标比较面积、服务周期和能量。可把“服务损失不超过 3%，面积或能量至少一项改善 15%”作为继续投入的初始门槛，另一个物理指标需明确报告。这是研究预算选择，不是期刊录用标准，也不是当前已达结果。

若最终只是减少 SRAM 访问而九宏仍全部保留，应降低论文贡献预期；若取消后备宏后匹配 P&R 仍有稳定优势，才有理由替换旧标题。不得把原 $1.6945\times$ 周期模型全部归给这项改造。

C2：强对照把方向从部分和改为原始权重暂存

共享部分和不是本轮最有希望的主语。64 源窗口、最多两槽、归约器固定输入 0/1、相同 2,880 个冻结 B4 模板，按输出 tile 数加权。以现有 group-major K8 的非空消费者更新意图为分母，不重复计 TSBG 权重请求节省。

方案	FC1 更新意图减少	FC2 更新意图减少	额外向量载荷
共享部分和，独立分发	0.5399%	1.3030%	两个 Acc24：576 B
共享部分和，利用空闲输入分发	4.1065%	4.6667%	576 B
部分和与单源类联合选择	7.3825%	7.8170%	576 B
任意两个原始源；每次捕获另收一服务	8.0689%	8.0261%	两个 INT8 权重向量：192 B
任意两个原始源；捕获随权重返回完成	19.4891%	23.7257%	192 B

原始基线计数：FC1 2,383,264；FC2 715,426。所有选择器看见已到齐的窗口并穷举最优选择；选择延迟、槽端口、流水气泡没有计入。因此末行是机会的乐观上界，上一行是捕获成本敏感性，也不是实测周期。

末行平均每个按输出 tile 加权的窗口只省 2.75 / 1.01 次更新。这个数直接限制选择器能花多少关键路径服务；如果一次串行扫描不能被复用或重叠隐藏，19%–24% 的比例也可能兑现不了。


原始源对照允许选择重复目的掩码中的任意单个源，也允许单消费者源；比“只暂存恰好出现一次的多消费者模式”更强。即使另收一次捕获服务，它也已解释或超过部分和方案的聚合收益，故不能再把这些收益主要归因于共享归约。

这里的 INT8 载荷是已有权重 W，ATLIF 出口仍为二值。两个 raw 槽与两个 Acc24 槽不是严格等面积，物理比较时必须同时计注入网络和控制器。

部分和事件级定向核对 301,824 个 lane；原始源定向核对 19,968 个 lane，均零不一致。执行级数值回放只覆盖选定模板/窗口；全体 2,880 模板覆盖的是意图计数。

C2：把候选收窄到捕获与延迟投递

工作名：两槽原始权重延迟投递。沿用已有 K8 与 TSBG，研究请求返回之后的算术更新压缩：将少量已读权重从当前消费者更新中拿出，稍后借同一消费者归约器的空闲输入一起送入 Acc24。



每槽保存 96 lane × INT8 权重、源/层/窗口身份、已完成捕获位和待投递的四消费者掩码。最多两槽；只占用八输入树中 bank0/1 对当前消费者为空的位置，两槽可交叉选择两个位置。当前计数尚未实现该 2×2 选择网络。

必须保留捕获专用请求。某个源组的普通 ALU 更新可能被完全拿走，但取权重请求不能因此消失。需要把 “仍要捕获权重” 和 “仍有普通消费者更新” 分开判断；同时支持同组两个槽写入或显式缓存。否则不满足零额外服务捕获假设。

权重捕获完成后，只有目的、符号与累加上下文匹配的已就绪操作可以合并。尚未投递的消费者必须在窗口结束前显式分发；不能将空操作伪装成已有更新以隐藏成本。窗口、层、token 组及 continuation 边界都必须清空或精确保存状态。

下一步先实现一个有成本的选择规则，例如利用消费者位图识别 “可移除独立更新、且后面存在合法输入空位” 的少量源。该规则尚未得到本轮数据验证。对照必须给相同的窗口信息；需要报告它保留了多少穷举收益，以及选择是否跨输出 tile 复用。

必须匹配的物理轴：原 K8/TSBG；加入等量旁路/注入网络但不暂存；一槽与两槽原始权重；共享部分和对照。比较 accepted mem_req、Acc24 更新、端口停顿、活跃状态、面积和能量。目标是证明少更新可转化为电路收益，不能再声称增加一项权重广播加速。

相关原理来自 operand collection、Gustavson/广播和稀疏执行。ELSA 与 Gamma 是直接数据流对照 [6,8]；RSR 是共享归约的强近邻 [7]。本轮尚未建立 “没人做过这种暂存” 的结论，后续贡献应落在固定八 bank、四上下文下的可实现协议与同资源实测。

新增方向：优先统计 PSN，再判断注意力岛

候选一：T=10 PSN 的保守输出判定。overlay 的 PSN 具有跨时间仿射路径，不能套用普通复位 LIF 的提前停止。对一个输出 i，写作 $h_i = b_i + \sum_j A_{ij} x_j$ 。若尚未消费输入的合法范围是 $[l_j, u_j]$ ，可计算：

$$L_i = \text{已完成和} + \sum \text{未完成} \min(A_{ij} l_j, A_{ij} u_j)$$

$$U_i = \text{已完成和} + \sum \text{未完成} \max(A_{ij} l_j, A_{ij} u_j)$$

若 U_i 严格低于阈值，该输出确定不发放；若 L_i 达到阈值且边界约定一致，可确定发放。停止的是这个输出的后续乘加，不能停止仍被另外九个输出消费的输入。以上是本轮数学推导，尚无 ep34 跳过率。[10]

已有 ComPreEND 研究早期负输出检测，DPES 使用预测性提前停止；ADET 的出版商可见材料也涉及阈值网络精确提前判定。[11–13] 因而新意不能只是“发现不会发放就跳过”。需要证明冻结 PSN 的时间矩阵允许便宜、紧致且数值安全的界。

统计门：从 ep34 取真实 A、偏置、阈值及输入轨迹；记录每个图上活跃 T=10 模块的首次可判定时间、上下界开销、仍需保留的输入读。浮点求和/TF32 舍入必须纳入保守界；若另设定点部署，需要独立功能与 AEE 评价。低发放率本身不保证能提前判定。

候选二：Motion-XOR 的 K 时间配对驻留。T_w=2 时，同一 K 对的 XOR 计数可复用；可研究配对读入、K_{peer} 保留和 gated-K 消费之间的存储服务。原 RTL 已有分数叶，三 popcount 本身不足以成为新贡献。 α -XNOR 已包含共静默思路，混 T 展开也有硬件先验。[14,15]

这一候选仍须先完成 ep34 的注意力份额与行/lane 脏率统计。原始软件分数与 Q7 部署叶不能默认等价；450 token 的归一化、K1 到达后才能确定 K0 分数等因果关系要完整保留。普通对照若已经保存 K，不可再计算一次虚构的读写节省。

不增加的方向。小块压缩仅作存储格式研究：EBPC、tileANS 可借鉴，但必须测实际物理 word 访问，不能用编码 bit 数替代单口随机访问成本。[16,17] 光流方向预测唤醒与实值 ATLIF 均需另开算法评价，本轮没有偷用 ep34 的 AEE。

执行顺序、证据缺口与复现

第一阶段已完成：有强对照的 CPU 筛查。C1 优先四槽验证，再研究两槽能否取得更好的面积/能量权衡。C2 优先原始权重暂存，暂停以共享部分和为主贡献的实现投入。PSN 保持统计候选。

下一阶段的顺序。先把 C1 槽读写/权重重取与 C2 捕获/选择器写成可计时模型，增加未参与选择的 K 分区和样本；达到内部投入门后再进入隔离 RTL。随后在相同工作负载完成 VCS、DC/PT、Formality，最后做匹配的布局布线与能量评价。已有失败封存任务不因本研究自动恢复。

待回答的问题	当前知道什么	决策影响
C1 是否可实际取消九个父宏	CPU 可无后备精确执行，四槽工作增量很小	无物理面积优势则降低优先级
C1 新时序是否变慢	操作计数；未计新端口和权重交付	不能报 RTL 加速
C2 廉价选择器能否保留收益	穷举上界有空间；每窗口节省服务有限	先实现选择与捕获，不先扩展 Acc24 树
Comperity 是否覆盖关键近邻	出版商摘要已确认差分/无状态方向	全文缺口未关闭，不作排他首创声明
PSN / 注意力能否进入主线	身份与算术约束明确，收益未测	不把旧注意力 0.6% 当新测份额

本目录保留结果、源码和输入 SHA256。[results/evidence_summary.json](#) 可追溯本报告主要数值；[provenance.json](#) 绑定输入、脚本和结果，不授予 EDA 准入。

复现使用 Python 3.12 与 NumPy。[scripts/screen_forest_recompute.py --all-spatial](#) 重跑 C1 5,640 tile；[scripts/screen_merge_controls.py](#) 与 [scripts/screen_source_staging.py](#) 重跑 C2 强对照。具体命令见同目录 README。旧探索结果仍保留，并明确哪一轮已被更强对照取代。

研究文件放在规范 idea 目录；未改生产 RTL、TCAS-II 主稿、docs/359 或原封存结果。只以 TCAS-II 为电路投稿出口。报告中的内部实现名称与实验流水号不会自动成为论文标题或正文术语。

对投稿目标的判断。这轮找到了可检验的新电路问题，并淘汰了收益解释不成立的故事；尚没有足够证据给出强 accept 或稳 accept 判断。最接近短文形态的是“一个具体状态/端口机制 + 可解释的物理优势”，最终选哪条由匹配实测决定。

一手来源与访问边界

- [1] Chiyue Wei et al. Prosperity, HPCA 2025。已读作者全文；用于二值 product sparsity 和子集复用的先验边界。 [作者全文](#)
- [2] Chiyue Wei, Bowen Duan et al. Phi: Leveraging Pattern-based Hierarchical Sparsity for High-Efficiency Spiking Neural Networks, ISCA 2025。已读作者全文；双向残差与模式回退。 [作者全文](#)
- [3] Cong Guo et al. Transitive Array: An Efficient GEMM Accelerator with Result Reuse, ISCA 2025。已读作者全文；结果复用数据流。 [作者全文](#)
- [4] Paras Jain et al. Checkmate, MLSys 2020。官方论文页；重算与存储交换。 [官方论文页](#)
- [5] Marisa Kirisame et al. Dynamic Tensor Rematerialization, ICLR 2021。作者稿页面；在线重算先验。 [作者稿](#)
- [6] Guowei Zhang, Nithya Attaluri, Joel S. Emer, Daniel Sanchez. Gamma, ASPLOS 2021。已读作者 PDF；Gustavson、缓存及调度。 [作者 PDF](#)
- [7] Mohsen Dehghankar, Mahdi Erfanian, Abolfazl Asudeh. An Efficient Matrix Multiplication Algorithm for Accelerating Inference in Binary and Ternary Neural Networks, ICML 2025。官方页与作者全文；RSR/RSR++。 [官方论文页](#)
- [8] Kang You et al. ELSA: An ELastic SNN Inference Architecture for Efficient Neuromorphic Computing, ISCA 2026。已读作者全文；SNN 数据流近邻。 [作者全文](#)
- [9] Jiahao Zhou et al. Comperity: A Stateless Spiking Neural Network Accelerator with Differential Spike Encoding, ACM TACO, 在线 2026-07-24。Crossref 出版商元数据与摘要可核验；全文未取得。 [出版商 DOI](#)

一手来源与访问边界（续）

[10] Wei Fang et al. Parallel Spiking Neurons with High Efficiency and Ability to Learn Long-term Dependencies, NeurIPS 2023. 作者稿页面及本地 PSN 实现对照；不能将本报告的区间推导说成该文已有实现。 [作者稿](#)

[11] Namhyung Kim et al. ComPreEND: Computation Pruning through Predictive Early Negative Detection for ReLU in a Deep Neural Network Accelerator, IEEE Transactions on Computers, 2022. 机构论文页、完整摘要；对细节结论保持限定。 [机构论文页](#)

[12] Ladan Sayadi, Mohammad Hossein Moaiyeri, Somayeh Timarchi. ADET, AEÜ, 2026. 出版商可见材料用于近邻提醒；全文未取得，不据此排除所有精确阈值设计。 [出版商 DOI](#)

[13] Yijie Miao, Makoto Ikeda. DPES, IEICE Electronics Express, 2024. 已读官方全文；预测性早停不是冻结模型无损跳过的证据。 [官方全文](#)

[14] Xiao et al. Rethinking Spiking Self-Attention Mechanism: Implementing α -XNOR Similarity Calculation in Spiking Transformers, CVPR 2025. 官方论文；共静默项的直接先验。 [CVF 论文](#)

[15] Bo-Yu Chen, Tian-Sheuan Chang. Hardware Efficient Accelerator for Spiking Transformer With Reconfigurable Parallel Time Step Computing, 2025 作者稿。已读全文；可配置时间步硬件，不能改写为本项目流片证据。 [作者全文](#)

[16] Lukas Cavigelli, Georg Rutishauser, Luca Benini. Extended Bit-Plane Compression, JETCAS 2019. 已读作者全文；压缩器吞吐和块组织需要重新匹配八 bank。 [作者全文](#)

[17] Hongshi Tan et al. tileANS, 2026-06 作者预印本。已读作者全文；块独立编码可借鉴，不能沿用其所有随机访问排他性表述。 [作者全文](#)

访问日期：2026-09-06。来源置信度区分全文、官方摘要与出版商预览；未访问全文的项目不用于证明某个细节不存在。上述来源支撑先验边界，本报告所有新数值均来自本地 CPU 筛查。